UNIVERSIDADE FEDERAL DO AMAZONAS - UFAM
PRO-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
DEPARTAMENTO DE APOIO A PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

UM ESTUDO SOBRE O MÉTODO DE DIREÇÕES CONJUGADAS PARA OTIMIZAÇÃO IRRESTRITA

Bolsista: Francisco Lima da Silva, FAPEAM.

Este trabalho teve apoio financeiro da FAPEAM.

Manaus
2021

UNIVERSIDADE FEDERAL DO AMAZONAS
PRO-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
DEPARTAMENTO DE APOIO A PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

RELATÓRIO FINAL
PIB-E/0074/2020

UM ESTUDO SOBRE O MÉTODO DE DIREÇÕES CONJUGADAS PARA OTIMIZAÇÃO IRRESTRITA

Bolsista: Francisco Lima da Silva, FAPEAM.
Orientador: Prof. Dr. Roberto Cristóvão Mesquita Silva

Manaus
2021

Resumo

O projeto aborda em sua primeira parte o estudo dos princípios básicos do Método das Direções Conjugadas. Na segunda parte, os princípios serão utilizados para descrever o Método com o intuito de resolver problemas de minimizar uma função de uma ou mais variáveis. Por fim, será investigado as vantagens e desvantagens do método com a utilização de algum software computacional.

Palavras-chave: Otimização, Método do Gradiente, Direção Conjugada.

Sumário

	Resumo	3
1	**REVISÃO BIBLIOGRÁFICA**	**6**
1.1	**Conceitos Preliminares**	**6**
1.1.1	Sequências	6
1.1.2	Conceitos inicias de Topologia	8
1.1.3	Resultados de Álgebra Linear	8
1.1.4	Fórmula de Taylor	9
1.2	**Introdução á Otimização**	**11**
1.2.1	O problema de Otimização	11
1.2.2	Condições de Otimalidade	12
1.3	**Convexidade**	**15**
1.3.1	Conjuntos convexos	15
1.3.2	Funções Convexas	19
2	**MÉTODOS UTILIZADOS**	**21**
3	**RESULTADOS E DISCUSSÕES**	**22**
3.1	**Algoritmos**	**22**
3.1.1	Algoritmos de descida	22
3.2	**Métodos de Busca Unidirecional**	**24**
3.2.1	Busca Exata - Método da Seção Áurea	25
3.2.2	Busca Inexata- Condição de Armijo	28
3.3	**Método das Direções Conjugados**	**29**
3.3.1	Direções Conjugadas	30
3.3.2	Algoritmo das direções conjugados para funções quadráticas	33
3.3.3	Extensão para funções não-quadráticas	36
3.4	**Teste Computacional**	**38**
3.4.1	Funções quadráticas	38
3.4.2	Funções não-quadráticas	39
3.4.2.0.1	Funções Exatas	39
3.4.2.0.2	Funções inexatas	39
	REFERÊNCIAS	**42**

Introdução

A Programação Matemática ou Otimização configura uma área da matemática aplicada ao que se refere os estudos de determinados problemas, nos quais estamos empenhados em encontrarmos um mínimo ou máximo da função sujeita a nenhuma ou mais restrições. A otimização pode ser vista como um ramo da matemática pura, mas tem aplicações em quase todos os ramos da ciência e tecnologia. Dentre eles, podemos citar a engenharia, economia, informática, logística, medicina, processos sísmicos e transporte. As aplicações dos métodos de otimização são de extrema importância na resolução de problemas da vida real. No entanto, não se pode excluir o papel dos estudos teóricos na otimização, e o cientista estará sempre em melhor posição para usar técnicas numéricas de maneira eficaz se compreender algum dos fundamentos teóricos básicos. Dentre os métodos de otimização existentes na literatura destaca-se o Método de Direções Conjugadas.

Esse método se destaca pelo fato de estar inserido na classe de métodos de primeira ordem, ou seja, aquelas que usam apenas informações da função gradiente, enquanto o método do Gradiente ou de Cuchy pode gastar uma infinidade de passos para resolver uma quadrática, Newton a resolve em um passo. Veremos que o método de direções conjugadas minimiza uma quadrática definida no espaço n dimensional usando no máximo n passo.

Na oportunidade, o referido projeto o estudante se submeterá ao estudo dos conceitos e propriedades necessários para que o estudo do Método de Direção Conjugadas. Por tal importância do método é que nesse projeto também será desenvolvido um estudo apurado sobre as suas características, vantagens e desvantagens. Espera-se com isso, que esse estudo venha acrescentar ainda mais no amadurecimento científico e na abrangência alcançada em matemática do estudante.

1 Revisão bibliográfica

1.1 Conceitos Preliminares

Neste capítulo será apresentado conceitos preliminares e resultados de Análise no $\mathbb{R}^n$ e Álgebra Linear, e como consequência, serão introduzidos conceitos de otimização e convexidade, assuntos que são relevantes para este trabalho.

1.1.1 Sequências

Uma sequência em $\mathbb{R}^n$ é uma aplicação $k \in \mathbb{N} \to x^k \in \mathbb{R}^n$, definida no conjunto $\mathbb{N}$ dos números naturais. Denotaremos uma sequência por $(x^k)_{k\in\mathbb{N}}$, ou simplesmente por (x_k). Iremos considerar que $\mathbb{N} = \{0, 1, 2, 3, ...\}$

Definição 1. *Dizemos que o ponto $\bar{x} \in \mathbb{R}$ é o limite da sequência (x^k) quando, dado um $\epsilon > 0$, é possível obter um $\bar{k} \in \mathbb{N}$ tal que*

$$k \geq \bar{k} \Rightarrow ||x^k - \bar{x}|| < \epsilon. \tag{1.1}$$

Desta forma, dizer que a sequência (x^k) converge para $\bar{x}$ e será denotado por $x^k \to \bar{x}$ ou $\lim_{k\to\infty} x^k = \bar{x}$.

Teorema 1. *Se uma sequência (x^k) converge para um limite $\bar{x}$, então toda subsequência $(x)^{k_i}_{i\in\mathbb{N}}$ também converge para $\bar{x}$.*

Demonstração. Dado $\varepsilon > 0$, existe um $\bar{k} \in \mathbb{N}'$ tal que para todo $k \geq \bar{k}$ tem-se $||x^k - \bar{x}|| < \varepsilon$. Assim, dado $i \geq \bar{k}$, temos $k_i \geq k_{\bar{k}} \geqslant \bar{k}$. Portanto $||x^{k_i} - \bar{x}|| < \varepsilon$. ■

Observação 1. *O limite de uma subsequência $(x^k)_{k\in\mathbb{N}}$ é chamado valor de aderência ou ponto de acumulação da sequência (x_k), onde $\mathbb{N}'$ é um conjunto infinito*

Definição 2. *Uma sequência $(x^k) \subset \mathbb{R}^n$ é limitada, quando o conjunto formado pelos seus elementos é limitado, ou seja, quando existe um numero real $N > 0$ tal que $||x^k|| \leq N$ para todo $k \in \mathbb{N}$.*

Teorema 2. *Toda sequência convergente é limitada.*

Demonstração. A demonstração deste Teorema pode encontrada ser na referência (LIMA, 2004) ■

Teorema 3. *(Bolzano-Weierstrass). Toda sequência limitada em $\mathbb{R}^n$ possui uma subsequência convergente.*

Demonstração. A demonstração deste Teorema pode encontrada ser na referência (LIMA, 2004) ■

Teorema 4. *Uma sequência limitada em $\mathbb{R}^n$ é convergente se, e somente se, possui um único ponto de acumulação.*

Demonstração. Seja (x^k) um sequência limitada então existe um $N \in \mathbb{R}$ tal que para todo $k \in \mathbb{N}$ temos $||x^k|| \leq N$ ou $||x^k|| \geq N$, como toda sequência limitada tem uma subsequência convergente. Tomemos uma subsequência convergente decrescente (x^k). Pelo **Teorema 3** temos que $\lim_{k\to\infty}(x^k) = x^*$, mas se aplicarmos a norma nos dois lados temos que $\lim_{k\to\infty} ||(x^k)|| = ||x^*||$

$$||x^k|| \geq N$$

ou seja

$$||x^*|| = N$$

E sabemos que x^* é seu ponto de acumulação, pois a sequência é limitada e os pontos convergem para x^* assim provando que uma função limitada so converge quando existe ao menos um ponto de acumulação que pertence a sequência.

■

Definição 3. *Dizemos que a sequência (x^k) é não-decrescente quando $x^{k+1} \geq x^k$ para todo $k \in \mathbb{N}$. Se as desigualdades forem estritas, diremos que (x^k) é crescente no primeiro caso e decrescente no segundo. Em qualquer uma destas situações a sequência (x^k) é dito monótona.*

Teorema 5. *Seja $(x^k) \subset \mathbb{R}$ uma sequência monótona que possui uma subsequência convergente, digamos $x^k \overset{\mathbb{N}'}{\to} \bar{x}$*

Demonstração. A demonstração deste Teorema pode ser encontrado na referência (RIBEIRO; KARAS, 2001) ■

Definição 4. *Seja $(x^k) \subset \mathbb{R}$ uma sequência limitada. Definimos o limite inferior da sequência (x^k) como seu menor ponto de acumulação e denotamos por $\liminf x^k$. Analogamente definimos o limite superior da sequência como seu maior ponto de acumulação e denotamos por $\limsup x^k$.*

Definição 5. *Considere as sequências $(v^k) \subset \mathbb{R}^n$ e $(\lambda_k) \subset \mathbb{R}\backslash\{0\}$, com $\lambda_k \longrightarrow 0$. Dizemos que $v^k = o(\lambda_k)$ quando $\dfrac{v^k}{\lambda_k} \longrightarrow 0$. Mais geralmente, considere $g : I \subset \mathbb{R} \longrightarrow \mathbb{R}^n$. Dizemos que $g(\lambda) = o(\lambda)$ quando $g(\lambda_k) = o(\lambda_k)$ para toda sequência $(\lambda_k) \subset I$ com $\lambda_k \longrightarrow 0$.*

1.1.2 Conceitos inicias de Topologia

Definição 6. *Um ponto $\bar{x} \in \mathbb{R}^n$ é dito de fronteira de um conjunto $X \subset \mathbb{R}^n$ quando qualquer vizinhança de $\bar{x}$ contém algum elemento do complementar de X.*

Definição 7. *Um conjunto X é fechado quando contém sua fronteira, ou seja, quando Fr $X \subset X$.*

De forma equivalente, podemos dizer $X \subset \mathbb{R}^n$ é fechado se, e somente se, toda sequência convergente formado por elemento de X tem seu limite em X.

Definição 8. *Um conjunto $X \subset \mathbb{R}^n$ é limitado quando existe $M > 0$ tal que $||x|| \leq M$, para a todo $x \in X$.*

Quando $X \subset \mathbb{R}^n$ for fechado e limitado, dizemos que ele é compacto.

Definição 9. *Um ponto $\bar{x} \in X \subset \mathbb{R}^n$ é chamado um ponto interior de X quando é centro de alguma bola aberta contido em X, ou seja, quando existe $\delta > 0$ tal que $B(\bar{x}, \delta) \subset X$.*

O interior de um conjunto X é formado pelos pontos interiores a X e denotado por $\int X$.

Definição 10. *Um conjunto $X \subset \mathbb{R}^n$ é aberto quando todo os seus pontos são interiores, ou seja,$\int X = X$*

Definição 11. *Dados $x \neq y \in \mathbb{R}$, a reta que une esses dois pontos é o conjunto.*

$$xy = \{(1-t)x + ty; t \in \mathbb{R}\} \tag{1.2}$$

Definição 12. *Dados $x \neq y \in \mathbb{R}^n$, o segmento de reta de extremos x e y é o conjunto*

$$[a, b] = \{(1-t)x = yt; 0 \leq t \leq 1 \in \mathbb{R}\} \tag{1.3}$$

1.1.3 Resultados de Álgebra Linear

Para estudo mais aprofundado deste tópico as referências ...

Definição 13. *O núcleo de uma matriz $A \in \mathbb{R}^{m \times n}$, denotado por $N(A)$, é um subconjunto de $\mathbb{R}^n$ formado por todas as soluções de sistema homogêneo $Ax = 0$, ou seja,*

$$N(A) = \{x \in \mathbb{R}^n \mid Ax = 0\} \tag{1.4}$$

Temos que $N(A)$ é um subespaço vetorial de $\mathbb{R}^n$. O número $\dim(N(A))$ é chamado nulidade de A.

Lema 1. *Considere $A \in \mathbb{R}^{m \times n}$. Então $N(A^T A) = N(A)$*

Demonstração. A demonstração deste Teorema pode ser encontrado na referência (RIBEIRO; KARAS, 2001) ■

Definição 14. *A imagem de uma matriz $A \in \mathbb{R}^{m\times n}$ é conjunto $Im(A) = \{y \in \mathbb{R}^m \; y = Ax$, para algum $x \in \mathbb{R}$ $\}$.*

Definição 15. *Seja $A \in \mathbb{R}$ uma matriz simétrica. Dizemos que A é definida positiva quando x^TAx, para todo $x \in \mathbb{R}^n$ $\{0\}$. Tal propriedade é denotada por $A > 0$. Se $x^TAx > 0$, para todo $x \in \mathbb{R}^n$, A é dita semi definida positiva, fato este denotado por $A \geq 0$.*

Definição 16. *Seja $A \in \mathbb{R}^{n\times n}$ uma matriz simétrica. Dizemos que A é indefinida quando existem $x, y \in \mathbb{R}^n$ tais que $x^TAx < 0 < y^TAy$.*

Lema 2. *Se $A \in \mathbb{R}^{n\times n}$ é uma matriz simétrica com λ_1 e λ_2 o menor e o maior autovalor, respectivamente, então*

$$\lambda_1||x||^2 \leq x^TAx \leq \lambda_n||x||^2 \tag{1.5}$$

para todo $x \in \mathbb{R}^n$.

Demonstração. A demonstração deste Teorema pode ser encontrado na referência (RIBEIRO; KARAS, 2001) ■

1.1.4 Fórmula de Taylor

Utilizaremos derivadas de várias variáveis. As aproximações de Taylor para uma função são muito importante na área da otimização. Consideremos uma função de classe C^2, $f : \mathbb{R}^n \longrightarrow \mathbb{R}$

Gradiente é representado da seguinte forma:

$$\nabla f = \begin{bmatrix} \dfrac{\partial f}{\partial x_1} \\ \\ \dfrac{\partial f}{\partial x_2} \\ \vdots \\ \dfrac{\partial f}{\partial x_n} \end{bmatrix}$$

Hessiana é representado da seguinte forma:

$$\nabla^2 f = \begin{bmatrix} \dfrac{\partial^2 f}{\partial x_1 \partial x_1} & \dfrac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \dfrac{\partial^2 f}{\partial x_1 \partial x_n} \\ \dfrac{\partial^2 f}{\partial x_2 \partial x_1} & \dfrac{\partial^2 f}{\partial x_2 \partial x_2} & \cdots & \dfrac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \cdots & \vdots \\ \dfrac{\partial^2 f}{\partial x_n \partial x_1} & \dfrac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \dfrac{\partial^2 f}{\partial x_n \partial x_n} \end{bmatrix}$$

Temos $f : \mathbb{R}^n \longrightarrow \mathbb{R}^m$, uma função vetorial. Sua derivada, denominada de Jacobiano é dada por,

$$J_f = f' = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}$$

Teorema 6. *(Taylor de primeira ordem) Considere $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ uma função diferenciável e $\bar{x} \in \mathbb{R}^n$. Então podemos escrever*

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + r(x)$$

com $\lim_{x \longrightarrow \bar{x}} \frac{r(x)}{||x - \bar{x}||} = 0$

O polinômio $p(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x})$ é uma aproximação linear para f em torno de $\bar{x}$ é chamado de polinômio de Taylor de ordem 1 da função. Então para x muito próximo de $\bar{x}$, o resto $r(x) = 0$ e vai para zero mais rápido que $||x - \bar{x}||$.

Teorema 7. *(Taylor de segunda ordem). Se $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ uma função diferenciável, e e $\bar{x} \in \mathbb{R}^n$, então*

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}) + r(x),$$

com $\lim_{x \longrightarrow \bar{x}} \frac{r(x)}{||x - \bar{x}||} = 0$

Percebe-se que é da mesma forma que o Teorema anterior, o polinômio

$$p_2 = f(x) = f(\bar{x}) + \nabla f(\bar{x})^T (x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x})$$

é uma aproximação quadrática para f em torno do ponto $\bar{x}$, e é chamado polinômio de Taylor de ordem 2 da função. Então para x muito próximo de $\bar{x}$, o resto $r(x) = 0$ e vai para zero mais rápido que $||x - \bar{x}||^2$.

Teorema 8 (Teorema do Valor Médio)**.** *Considere $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ contínua e $\bar{x}, d \in \mathbb{R}^n$. Se f é diferenciável no segmento $(\bar{x}, \bar{x} + d)$, então existe $t \in (0, 1)$ tal que*

$$f(\bar{x} + d) = f(x) + \nabla f(\bar{x} + td)^T d$$

Demonstração. A demonstração deste Teorema pode ser na referência (RIBEIRO; KARAS, 2001) ■

Teorema 9 (Desigualdade do Valor Médio). *Considere $f : \mathbb{R}^n \longrightarrow \mathbb{R}^m$ contínua e $\bar{x}, d \in \mathbb{R}^n$. Se f é diferenciável no segmento $(\bar{x}, \bar{x}+d)$ e $||J_f(x)|| \leq M$, para todo $x \in (\bar{x}, \bar{x}+d)$, então*

$$||f(\bar{x}+d) - f(\bar{x})|| \leq M||d||.$$

Demonstração. A demonstração deste Teorema pode ser na referência (RIBEIRO; KARAS, 2001) ■

1.2 Introdução á Otimização

1.2.1 O problema de Otimização

A forma mais usual de escrever um problema de otimização, desta forma:

$$\text{minimizar } f(x)$$

$$\text{sujeito a } x \in \Omega$$

onde $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ é uma função arbitrária e $\Omega \subset \mathbb{R}^n$ é um conjunto qualquer.

Definição 17. *Considere uma função $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ e $x^* \in \Omega \in \mathbb{R}^n$. Dizemos que x^* é um minimizador local de f em Ω quando existe $\delta > 0$, tal que $f(x^*) \leq f(x)$, para todo $x \in B(x*, \delta) \cap \Omega$. Caso $f(x^*) \leq f(x)$, para todo $x \in \Omega, x^*$ é dito minimizador global de $f em \Omega$.*

Observação:

Quando as desigualdades na definição acima forem irrestritos para $x \neq x^*$, diremos que x^* é minimizador irrestrito. Se o conjunto Ω não estiver definido, temos que $\Omega = \mathbb{R}^n$, significa que é um problema irrestrito.

Teorema 10 (Weierstrass). *Sejam $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ contínua e $\Omega \subset \mathbb{R}^n$ compacto não vazio. Então existe minimizador global de f em Ω.*

Demonstração. Sabemos que f é compacto e limitado inferiormente. Então temos $f(\Omega) = \{f(x)|x \in \Omega\}$. Iremos supor por absurdo que conjunto não é limitado inferiormente. Então para todo $k \in \mathbb{N}$, existe $x^k \in \Omega$ tal que $f(x^k) \leq -k$. Como a sequência (x^k) está no compacto Ω, ela possui uma subsequência convergente para um ponto de Ω, digamos $x^k \longrightarrow \bar{x} \in \Delta$. Pela continuidade de f, temos $f(x^k) \longrightarrow f(\bar{x})$, uma contradição, pois $f(x^k) \to \infty$. Considere $f^* = \inf\{f(x)|x \in \nabla\}$. Então para todo $k \in \mathbb{N}$, existe $x^k \in \Omega$ tal que

$$f^* \leq f(x) \leq f^* + \frac{1}{k}$$

, percebe-se para um k muito grande

$$f^* \leq f(x^k) \leq f^*$$

ou seja $f(x^k) \to f^*$. Omas sabemos que $f(x^k \to f(x^*))$, com $x^* \in \Omega$. Pela unicidade do limite, temos $f(x^*) = f^* \leq f(x)$ (pois f^* é ínfimo), para todo $x \in \Omega$, o que completa a demonstração. ■

Definição 18. *Dizemos que a função $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ é coerciva quando*

$$\lim_{||x|| \to \infty} f(x) = \infty$$

ou seja, quando para todo $M > 0$, existe $r > 0$ tal que $f(x) > M$ sempre que $||x|| > r$.

Teorema 11. *Seja $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ uma função contínua e coerciva. Então, f tem um minimizador global.*

Demonstração. Seja $a \in \mathbb{R}^n$ e $b = f(a)$. Como f é coerciva, temos que existe $r > 0$ tal que $f(x) > b$ sempre que $||x|| > r$. O conjunto $B = \{x \in \mathbb{R}^n | ||x|| \leq r\}$ é compacto, portanto, pelo Teorema de Weiertrass, existe $x^* \in B$ tal que $f(x^*) \leq f(x)$ para todo $x \in B$. Além disso,$a \in B$, pois $f(a) = b$. Para $x \notin B$, temos $f(x) > b = f(a) \geq f(x^*)$.Logo prova que x^* é minimizador de f. ■

1.2.2 Condições de Otimalidade

Veremos agora as condições necessárias e suficientes para caracterizar um minimizador de um problema irrestrito.

Teorema 12 (Condição necessária de primeira ordem)**.** *Seja $f : \mathbb{R}^n \longrightarrow \mathbb{R}$ diferenciável no ponto $x^* \in \mathbb{R}^n$. Se $\bar{x}$ é um minimizador local de f, então*

$$\nabla f(x^*) = 0 \tag{1.6}$$

Demonstração. Considere $d \in \mathbb{R}^n \{0\}$ arbitrário. Como x^* é minimizador local, existe $\delta > 0$ tal que

$$f(x^*) \leq f(x^* + td), \tag{1.7}$$

para todo $t \in (0, \delta)$. Pela expansão de Taylor,

$$f(x^* + td) = f(x^*) + t\nabla f(x^*)^T d + r(t),$$

com $\lim_{t \to 0} \frac{r(t)}{0}$. Usando (2.3) e dividindo por t, obtemos

$$0 \leq \nabla f(x^*)^T d + \frac{r(t)}{t}.$$

Passando o limite quando $t \to 0$, obtemos $\nabla f(x^*)d \geq 0$. Se $\nabla f(x^*)$ não fosse nulo, poderíamos escolher $d = -\nabla f(x^*)$, resultando em $||\nabla f(x^*)||^2 = -\nabla f(x^*)^T \leq 0$, o que é uma contradição. Logo $\nabla = 0$. ■

Definição 19. *Um ponto $x^* \in \mathbb{R}^n$ que cumpre a condição (1.6) é dito ponto crítico ou ponto estacionário da função f.*

Teorema 13 (Condição necessária de segunda ordem)**.** *Seja $f : \mathbb{R}^n \to \mathbb{R}$ duas vezes diferenciável no ponto $x^* \in \mathbb{R}^n$. Se x^* é um minimizador local de f, então a matriz Hessiana de f no ponto x^* é semidefinida positiva, isto é*

$$d^T \nabla f(x^*) d \geq 0 \tag{1.8}$$

para todo $d \in \mathbb{R}^n$

Demonstração. Seja $d \in \mathbb{R}^n/\{0\}$ qualquer. Por Taylor, temos:

$$f(x^* + td) = f(x^*) + t\nabla f(x^*)^T d + \frac{2}{t^2} d^T \nabla f(x^*) d + r(t)$$

com $\lim_{t\to 0} \frac{r(t)}{t^2} = 0$. x^* é minimizador local, portanto, o Teorema 13 garante que $\Delta f(x^*) = 0$.

Com isso, para t suficientemente pequeno

$$0 \leq f(x^* + td) - f(x^*) = \frac{2}{t^2} d^T \nabla^2 f(x^*) d + r(t)$$

Dividindo por t^2 e passando o limite quando $t \to 0$, obtemos $d^T \nabla^2 f(x^*) d \geq 0$. ■

Exemplo 1. *Seja $f : \mathbb{R}^2 \to \mathbb{R}$ dada por $f(x) = (x_1 - x_2^2)(x_1 - \frac{1}{2}x_2^2)$. Verifique que $\bar{x} = 0$ é o único ponto estacionário de f e não é minimizador. No entanto fixada qualquer direção $d \in \mathbb{R}^n/\{0\}$, $\bar{x}$ minimiza localmente f ao longo de d.*

Resolução.

Calculando o gradiente de f ;

$$\nabla f(x) = \begin{pmatrix} 2x_1 - \frac{3}{2}x_2^2 \\ -3x_1x_2 + 2x_2^3 \end{pmatrix}$$

Então temos que, $\bar{x}$ é ponto estacionário e verificando, se $\nabla f(x) = 0$. Adquirimos $f(\frac{2}{3}x_2^2, x^2) = -\frac{x_2^4}{18} < 0 = f(\bar{x})$, então percebe-se que $\bar{x}$ não é minimizador local de f. Todavia, dado $d \in \mathbb{R}^n \ \{0\}$, temos

$$f(\bar{x} + td) = t^2(d_1 - td_2^2)(d_1 - \frac{1}{2}td_2^2) \tag{1.9}$$

Se $d_1 = 0$, então $f(\bar{x} + td) = \frac{1}{2}t^4 d_2^4 \geqslant 0$. Caso $d \neq 0$, a expressão $(d_1 - td_2^2)(d_1 - \frac{1}{2}td_2^2)$ é positiva em $t = 0$ e, por continuidade, para e fazendo $t \to 0$. Logo $\bar{x}$ minimiza localmente f ao longo de d.

Teorema 14 (Condição suficiente de segunda ordem)**.** *Seja $f : \mathbb{R}^n \to \mathbb{R}$ duas vezes diferenciável no ponto $x^* \in \mathbb{R}$. Se $\bar{x}$ é um ponto estacionário da função f e $\Delta^2 f(x^*)$ é definida positiva, então x^* é **minimizador local estrito** de f.*

Demonstração. Seja λ o menor autovalor de $\nabla^2 f(x^*)$. Temos, por hipótese, que esta matriz é definida positiva, portanto, todos os seus autovalores são positivos, com isso $\lambda > 0$. Além disso, pelo Lema 2, $d^T \nabla f(x^*) \geq \lambda ||d||^2$, para todo $d \in \mathbb{R}^n$. Pelo Teorema de Taylor de segunda ordem, ja usando o fato de x^* ser estacionário, temos

$$f(x^* + td) = f(\bar{x}) + \frac{1}{2} d^T \nabla^2 f(\bar{x^*}) d + r(d) \geq f(x^*) + \frac{1}{2}\lambda ||d||^2 + r(d)$$

onde o $\lim_{d \to 0} \frac{r(d)}{||d||^2} = 0$. Com isso, podemos escrever

$$\frac{f(x^* + td) - f(x^*)}{||d||^2} \geq \frac{\lambda}{2} + \frac{r(d)}{||d||^2}$$

Como $\lambda > 0$, temos que $\lim_{d \to 0}(\frac{\lambda}{2} + \frac{r(d)}{||d||^2}) > 0$, portanto, existe $\delta > 0$ tal que $\frac{\lambda}{||d||^2} > 0$, para todo $d \in B(0, \delta)/\{0\}$, com isso, $f(x^* + td) - f(x^*) > 0$, para todo $d \in B(0, \delta)/\{0\}$, ou palavras.

$$f(x^*) < f(x)$$

para todo $x \in B(x^*, \delta)$ $\{x^*\}$. Portanto, x^* é minimizador local estrito de f. ■

Definição 20. *Considere uma função diferenciável $f : \mathbb{R}^n \to \mathbb{R}$ e $\bar{x} \in \mathbb{R}^n$ um ponto estacionário de f. Dizemos que $\bar{x}$ é um* ***Ponto de sela*** *da função f quando para todo $\epsilon > 0$ existem $x, y \in B(\bar{x}, \epsilon)$ tais que*

$$f(x) < f(\bar{x}) < f(y).$$

O teorema a seguir nos fornece uma condição suficiente (porém, não necessária) para que um ponto de sela.

Teorema 15. *Seja $f : \mathbb{R}^n \to \mathbb{R}$ duas vezes diferenciável no ponto estacionário $\bar{x} \in \mathbb{R}^n$. Se $\nabla^2 f(\bar{x})$ é indefinida, então $\bar{x}$ é ponto de sela de f.*

Demonstração. Como $\nabla^2 f(x)$ é indefinida, $m^T \nabla^2 f(\bar{x}) m < 0$ para alguns $m \in \mathbb{R}^n$ e $m^T \nabla^2 f(\bar{x}) m > 0$ para outros. Deste modo, considere $d \in \mathbb{R}^n$ tal que $d^T \nabla^2 f(\bar{x}) d < 0$. Por Taylor, e já usando o fato de $\bar{x}$ ser estacionário, temos que

$$\frac{f(\bar{x} + td) - f(\bar{x})}{t^2} = \frac{1}{2} d^T \nabla^2 f(\bar{x}) d + \frac{r(t)}{t^2}$$

com $\lim_{r(t) \to 0} \frac{r(t)}{t^2} = 0$. De maneira análoga à demonstração do teorema anterior, concluímos que:

$$f(\bar{x} + rd) < f(\bar{x}),$$

para t suficientemente pequeno. considere agora, $v \in \mathbb{R}^n$ tal que $v^T \nabla^2 f(\bar{x}) v > 0$. Da mesma forma, concluímos que $f(\bar{x} + tv) > f(\bar{x})$, para t suficientemente pequeno. Concluímos, portanto, que $\bar{x}$ é o ponto da sela. ■

Exemplo 2. *Seja $f : \mathbb{R}^2 \to \mathbb{R}$ dada por:*

$$f(x) = 2x_1^3 - 3x_1^2 - 6x_1 x_2 (x_1 - x_2 - 1)$$

Descreva os pontos estacionários da função f.

Resolução:

Temos $\nabla f(x) = \binom{6x_1^2-12x_1x_2-6x_1+6x_2^2+6x_2}{-6x_1^2+12x_1x_2+6x_1}$. Logo, os pontos estacionários são soluções do sistema abaixo:

$$\begin{cases} 6x_2^2 + 6x_2 = 0 \\ 6x_1^2 - 12x_1x_2 - 6x_1 = 0 \end{cases}$$

Verificamos, portanto, que pontos são $x^1 = \binom{0}{0}$, $x^2 = \binom{-1}{-1}$, $x^3 = \binom{1}{0}$, $x^4 = \binom{0}{-1}$. Além disso, verificamos que

$$\nabla^2 f = \begin{pmatrix} 12x_1 - 12x_2 - 6 & -12x_1 + 12x_2 + 6 \\ -12x_1 + 12x_2 + 6 & 12x_1 \end{pmatrix}$$

Considerando $A_j = \frac{1}{6}\nabla^2 f(x_j)$, teremos $A_1 = \begin{pmatrix} -1 & 1 \\ 1 & 0 \end{pmatrix}$, $A_2 = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}$, $A_3 = \begin{pmatrix} 1 & -1 \\ 1 & -2 \end{pmatrix}$ e $A_4 = \begin{pmatrix} -1 & 1 \\ 1 & -2 \end{pmatrix}$ Percebe-se que A_1 é indefinida, pois $u = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ e $v = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ então calculamos $u^T A_1 u$ e $v^T A_1 v > 0$. Portanto usando o Teorema 15 x^1 é ponto de sela. Por fim, $A_4 = -A_2 < 0$, implicando que x_4 é maximizador local.

1.3 Convexidade

Iremos aborda funções e conjuntos convexos, que tem propriedades muito interessantes. Para interessados neste tópico (RIBEIRO; KARAS, 2001).

1.3.1 Conjuntos convexos

Definição 21. *Um conjunto $C \subset \mathbb{R}^n$ é dito ser convexo quando dados $x, y \in C$, o segmento $[x, y] = \{(1-t)x + ty | t \in [0, 1]\}$ estiver inteiramente em C.*



Figura 1 – Conjuntos convexo e não convexo, respectivamente

Lema 3. *Sejam $u, v \in \mathbb{R}^n$ com $u \neq v$. Se $||u||_2 = ||v||_2 = r$, então $||(1-t)u + tv||_2 < r$ para todo $t \in (0,1)$.*

Demonstração. Pela desigualdade triangular, temos

$$||(1-t)u + tv|| \leq (1-t)||u||_2 + t||2||_2 = r.$$

Suponha, por absurdo, que $||(1-t)u + tv||_2 = r$. Então

$$(1-t)^2 u^T u + 2t(1-t)u^T v + t^2 v^T v = ||(1-t)u + tv||_2^2 = r^2.$$

Sabemos, por hipótese que $u^T u = v^T v = r^2$ e $t \in (0,1)$, obtemos $u^T v = r^2$. Portanto

$$||u - v|| = u^T u - 2u^T v + v^T v = 0$$

o que é uma contradição.Temos o potencial para concluir que $||(1-t)utv||_2 < r$, completando a demonstração. ■

Seja, $S \subset \mathbb{R}^n$, um ponto $z \in \mathbb{R}^n$ e o problema de encontrar um ponto de S mais próximo de z. Este assunto em questão pode não ter solução e quando tem, não garantimos unicidade, porém como iremos mostrar a seguir, se S é fechado, não existe solução. Agora se o conjunto for fechado e convexo, a solução é única e será chamada de projeção de z sobre S, denotada por $proj_S(z)$.

Lema 4. *Seja $S \subset \mathbb{R}^n$ um conjunto fechado não vazio. Dado $z \in \mathbb{R}^n$, existe $\bar{z} \in S$ tal que*

$$||z - \bar{z}|| \leq ||z - x||,$$

para todo $x \in S$

Demonstração. Como S é fechado, existe $\alpha = \inf\{||z - x|||x \in S\}$. Deste modo, para todo $k \in \mathbb{N}$, existe $x^k \in S$ tal que

$$\alpha \leq ||z - x^k|| \leq \alpha + \frac{1}{k}. \tag{1.10}$$

Em particular , temos que $||z - x^k|| \leq \alpha + 1, \forall k \in \mathbb{N}$. Logo, como x^k está fechado e limitado, com isso, possui uma subsequência convergente, digamos $x^k \to \bar{z}$. Usando novamente o fato de S ser fechado, temos que $\bar{z} \in S$. Além disso

$$||z - x^k|| \to ||z - \bar{z}||$$

Porém, pela equação (1.10), $||z - x^k|| \to \alpha$, portanto como toda subsequência deve convergir para o mesmo limite de sua sequência,concluímos $||z - \bar{z}|| = \alpha$, finalizando a demonstração. ■

Adicionando mais uma condição para o conjunto S (convexidade), obtemos que o ponto $z \in S$ mais próximo de z é único. De fato, considere o lema seguir.

Lema 5. *Seja $S \subset \mathbb{R}^n$ um conjunto não vazio , convexo e fechado. Dado $z \in \mathbb{R}$, existe um único $\bar{z} \in S$ tal que*

$$||z - \bar{z}||_2 \leq ||z - x||_2$$

Demonstração. A existência de $\bar{z}$ é garantida pelo **Lema 4**. Portanto, para provar a unicidade, suponha que existam $\bar{z} \neq \tilde{z} \in S$ tais que

$$||z - \bar{z}||_2 \leq ||z - x||_2 \text{ e } ||z - \tilde{z}||_2 \leq ||z - x||_2 \tag{1.11}$$

para todo $x \in S$. Como vale para todo $x \in S$, tomemos $x = \tilde{z}$ na primeira desigualdade, e $x = \bar{z}$ na segunda, obtendo:

$$||z - \bar{z}||_2 = ||z - \tilde{z}||_2$$

Por outro lado, o ponto $z^* = \frac{1}{2}(\bar{z} + \tilde{z})$ está no convexo S.Além disso, pelo **Lema 3**, com $r = ||z - \bar{z}||_2 = ||z - \tilde{z}||_2$ e $t = \frac{1}{2}$, temos

$$||z - z^*|| = ||(1 - t)(z - \bar{z}) + t(z - \bar{z})||_2 < r,$$

mas contradiz (1.11). Concluímos que o ponto$\bar{z}$ é único. ■

Observação 2. No **Lema 5** o resultado usa a norma euclidiana. E denotaremos

$$\bar{z} = proj_S(z).$$

O Teorema a seguir é um dos principais desta seção. Indicaremos, por simplicidade a norma euclidiana por $||.||$.

Teorema 16. *Sejam $S \subset \mathbb{R}n$ um conjunto não vazio, convexo e fechado, $z \in \mathbb{R}^n$ e $z = proj_S(z)$. Então*

$$(z - \bar{z})^T(x - z) \leq 0,$$

para todo $x \in S$.

Demonstração. Considere $x \in S$ um ponto arbitrário. Como S é convexo, dado $t \in (0, 1)$, temos que $(1 - t)\bar{z} + tx \in S$. Portanto

$$||z - \bar{z}|| \leq ||z - (1 - t)\bar{z} - tx|| = ||z - \bar{z} + t(\bar{z} - x)||$$

Deste modo,

$$||z-\bar{z}||^2 \leq ||z-(1-t)\bar{z}-tx|| = ||z-\bar{z}+t(\bar{z}-x)||^2 = ||z-\bar{z}||^2+2t(z-\bar{z})^T(\bar{z}-x)+t^2||\bar{z}-x$$

Sabemos que $t > 0$, portanto, teremos que $2t(z - \bar{z})^T(x - \bar{z}) \leq t||\bar{z} - x||^2$. Passando o limite quando $t \to 0$, chegamos em

$$(z - \bar{z})^T(x - \bar{z}) \leq 0$$

como queríamos demonstrar ■

O próximo resultado, mostra que a condição dada no teorema acima, não é apenas necessária, mas também suficiente para caracterizar a projeção.A seguir vejamos a demonstração.

Lema 6. *Sejam $S \subset \mathbb{R}^n$ um conjunto não vazio, convexo e fechado e $z \in \mathbb{R}^n$. Se $\bar{z} \in S$ satisfaz*

$$(z - \bar{z})^T(x - \bar{z}) \leq 0$$

para todo $x \in S$, então $\bar{z} = proj_S(z)$.

Demonstração. Considere $x \in S$, temos

$$||z - \bar{z}||^2 - ||z - x||^2 = -2z^T\bar{z} + \bar{z}^T\bar{z} + 2z^Tx - x^Tx$$

$$= (x - \bar{z})^T(2z - x - \bar{z})$$

$$= (x - \bar{z})^T(2(z - \bar{z}) - (x - \bar{z})) \leq (z - \bar{z})^T(x - \bar{z}) \leq 0$$

Isto prova que $\bar{z} = proj_S(z)$. ■

1.3.2 Funções Convexas

Definição 22. *Seja $C \subset \mathbb{R}^n$ um conjunto convexo. Dizemos que a função $f : \mathbb{R}^n \to \mathbb{R}$' é convexa em C quando*

$$f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y)$$

para todos $x, y \in C$ e $t \in [0, 1]$.

Teorema 17. *Sejam $f : \mathbb{R}^n \to \mathbb{R}$ uma função diferenciável e $S \subset \mathbb{R}^n$ convexo. A função f é convexa em S se, e somente se,*

$$f(y) \geq f(x) + \nabla f(x)^T(y - x)$$

para todo $x, y \in S$.

Demonstração. Considere uma função convexa, provemos que a desigualdade acima é válida. Para quaisquer $x, y \in S$ e $t \in (0, 1]$, definindo $d = y - x$, temos $x + td = x + ty - tx = (1 - t)x + ty \in S$, pois S é convexo e,

$$f(x + td) = f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y).$$

Daí, temos

$$f(y) - f(x) \geq \lim_{t \to 0^+} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d = \Delta f(x)^T(y - x)$$

Reciprocamente, considere $z = (1 - t)x + ty$, observe que

$$f(x) \geq f(z) + \nabla f(z)^T(x - z) \text{ e } f(y) \geq f(z) + \nabla f(z)(y - z)$$

Multiplicando a primeira inequação por $(1-t)$, a segunda por t, e somando-as, teremos:

$$(1-t)f(x)+tf(y) \geq (1-t)f(z)+(1-t)\nabla f(z)^T(x-z)+t\nabla f(z)^T(y-z)$$

Substituindo o valor de z e fazendo as devidas simplificações, chegaremos no resultado:

$$(1-t)f(x)+tf(y) \geq f((1-t)x+ty)$$

concluindo que f é convexa, o que completa a demonstração. ■

2 Métodos Utilizados

Neste projeto, o aluno fará uma abordagem sobre o método das direções conjugadas e o estudo da sua eficiência computacional. Assim, a iniciação científica em matemática aplicada é melhor realizada através de estudos dirigidos, seminários e palestras que criem na mente do aluno uma base de conhecimento pautada pelo rigor científico no âmbito da escrita, da expressão oral e do pensamento.

Este projeto está sendo desenvolvido através da exposição dos diversos conteúdos encontrados nas referências bibliográficas e ao longo dos 12 meses do projeto o bolsista estará desenvolvendo atividades de pesquisa bibliográfica, estudo dirigido e seminários determinados pelo orientador.

3 Resultados e Discussões

Neste capítulo será abordado Algoritmos de busca, o método das direções conjugadas e sua eficiência computacional.

3.1 Algoritmos

Na areá da otimização existe cálculos que são extremamente exaustivos e para resolver esse empecilho é utilizado algoritmos. Os algoritmos são compostos de processos iterativos. Considera-se um ponto inicial x^0, obtemos um ponto melhor x^1 e repetimos o processo gerando uma sequência $(x^k) \subset \mathbb{R}^n$ na qual função objetivo decresce.

3.1.1 Algoritmos de descida

De maneira geral as formas de construir um algoritmo consiste em escolher a partir de cada ponto obtido, uma direção para dar o próximo passo. Algumas maneiras escolher uma direção segundo a qual f decresce.

Definição 23. *Considere $f : \mathbb{R}^n \to \mathbb{R}$ um ponto $\bar{x} \in \mathbb{R}^n$ e uma direção $d \in \mathbb{R}/\{0\}$. Dizemos que d é uma direção de descida para f. a partir de $\bar{x}$, quando existe $\delta > 0$ tal que $f(\bar{x} + td) < f(\bar{x})$, para todo $t \in (), \delta$.*

O próximo teorema, é uma condição suficiente para uma direção ser de descida.

Teorema 18. *Se $\nabla f(\bar{x})^T d < 0$, então d é uma direção de descida para f, a partir de $\bar{x}$.*

Demonstração. Sabemos que

$$\nabla f(\bar{x})^T d = \frac{\partial f}{\partial d}(\bar{x}) = \lim_{t \to 0} \frac{f(\bar{x} + td) - f(\bar{x})}{t} < 0.$$

Usando a hipótese, e considerando a preservação do sinal, existe $\delta > 0$ tal que

$$\frac{f(\bar{x} + td) - f(\bar{x})}{t} < 0$$

para todo $t \in (-\delta, \delta), t \neq 0$. Portanto, temos que $f(\bar{x} + td) < f(\bar{x})$, para todo $t \in (0, \delta)$, o que completa demonstração. ■

Algoritmo 1 Algoritmo básico

Dado: $x^0 \in \mathbb{R}^n$
$k = 0$
REPITA enquanto $\nabla f(x^k) \neq 0$
    Calcule d^k tal que $\nabla f(x^k)^T d^k < 0$
    Escolha $t_k > 0$ tal que $f(x^k + t_k d^k) < f(x^k)$
    Faça $x^{k+1} = x^k + t_k d^k$
    $k = k + 1$

O Algoritmo 1 encontra um ponto estacionário ($\nabla f(x^*) = 0$) em um número finito de iterações, ou gera uma sequência ao longo da qual f decresce. A questão agora é saber se esta sequência tem algum ponto de acumulação, e caso tenha, se este ponto é estacionário. Temos abaixo um exemplo de uma função com duas sequências, que podem ser obtidas pelo algoritmo, onde as mesmas possuem pontos de acumulação, porém nenhum dos pontos é estacionário.

Considere $f : \mathbb{R} \to \mathbb{R}$ dada por $f(x) = x^2$ e as sequências $x^k = 1 + \frac{1}{k+1}$ e $y^k = (-1)^k + \frac{(-1)^k}{k+1}$.

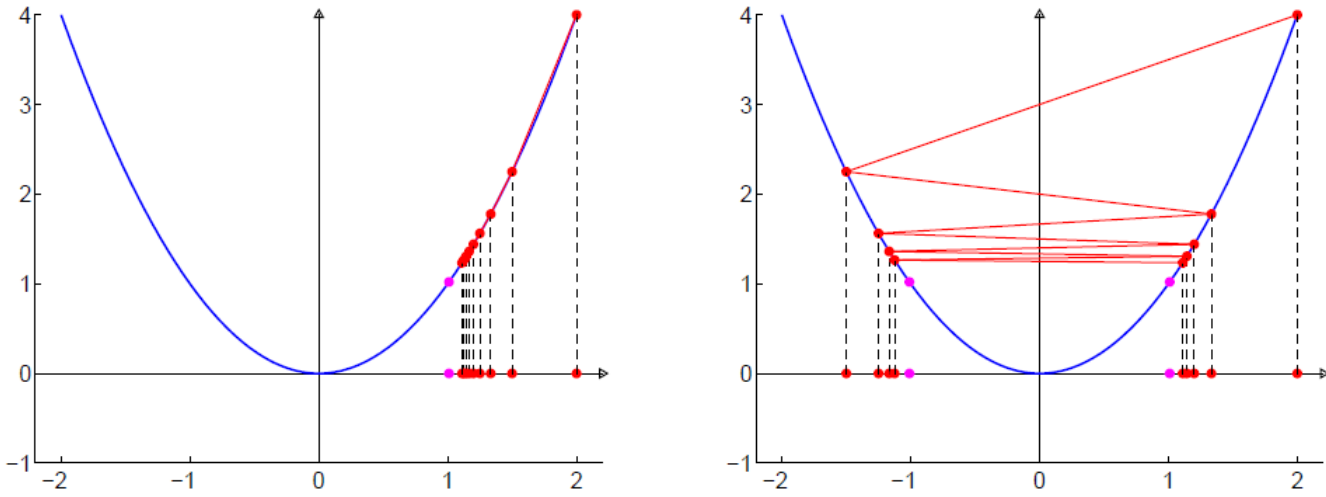


Figura 2 – Pode o ocorrer de algoritmo não encontrar ponto estacionário

podemos perceber pelo algoritmos, que $x^k \to 1$ e (y^k) tem dois pontos de acumulação, 1 e -1. Entretanto, nenhum desses pontos é estacionário.

Temos como objetivo garantir a convergência, a escolha da direção d^k e do tamanho do passo t_k, no Algoritmo 1 não pode ser feita de maneira arbitrária.

3.2 Métodos de Busca Unidirecional

Dada uma função $f : \mathbb{R}^n \to \mathbb{R}$, um ponto de $\bar{x} \in \mathbb{R}^n$ e uma direção de descida $d \in \mathbb{R}^n$, o objetivo será encontrar o tamanho do passo $\bar{t} > 0$ tal que

$$f(\bar{x} + \bar{t}d) < f(\bar{x})$$

Como foi abordado anteriormente, precisamos balancear o tamanho do passo com o decréscimo promovido em f. Para este problema, veremos duas abordagens. A primeira consiste em fazer uma busca exata a partir do ponto $\bar{x}$ segundo a direção d. Já a segunda, procura uma redução suficiente de f que seja de certo modo proporcional ao tamanho do passo.

3.2.1 Busca Exata - Método da Seção Áurea

Nosso objetivo neste caso é ambicioso e consiste em minimizar f a partir do ponto $\bar{x}$ na direção d. Mais precisamente, temos que resolver o problema

$$\text{minimizar } f(\bar{x}+td) \tag{3.1}$$

$$\text{sujeito a } t>0$$

Este problema é, em geral, difícil de se resolver. Entretanto, para certas funções, bem como um algoritmo. Antes porém vamos fazer pode ser resolvido de forma direta.

Exemplo 3. *Considere* $f:\mathbb{R}^2\to$ *dada por* $f(x)=\frac{1}{2}(x_1-2)^2+(x_2-1)^2, \bar{x}=\begin{pmatrix}1\\0\end{pmatrix}$ *e* $d=\begin{pmatrix}3\\1\end{pmatrix}$. *Faça a busca exata a partir de* $\bar{x}$, *na direção* d.

Resolução Note primeiro que d é de fato uma direção de descida, pois

$$\nabla f(\bar{x})^T d=\begin{pmatrix}-1 & -2\end{pmatrix}\begin{pmatrix}3\\1\end{pmatrix}=-5<0$$

Para fazer a busca, considere

$$g(t)=f(\bar{x}+td)=f(1+3t,t)=\frac{11t^2}{2}-5t+\frac{3}{2}$$

Para achar o minimizador, temos $g'(t)=11t-5=0$. Deste modo:

$$\bar{t}=\frac{5}{11} \text{ e } \bar{x}+td=\begin{pmatrix}1\\0\end{pmatrix}+\frac{5}{11}\begin{pmatrix}3\\1\end{pmatrix}=\frac{1}{11}\begin{pmatrix}26\\5\end{pmatrix}\approx\begin{pmatrix}2,36\\0,45\end{pmatrix}$$

. Na prática são aplicados problemas mais complexos que o exemplo acima e só podem ser resolvidos por meio de algoritmos. Vamos agora definir uma função para qual existem algoritmos para minimizá-la. Em seguida veremos o algoritmo da seção Áurea, que um ponto próximo de um minimizador com precisão que se queria. Este algoritmo será aplicado para a função $\varphi:[0,\infty)$

$$\varphi(t)=f(\bar{x}+td).$$

Definição 24. *Uma função contínua $\varphi : [0, \infty) \rightarrow$ é dita unimodal quando admite um conjunto de minimizadores $[t_1, t_2]$, estritamente decrescente em $[0, t_1]$ e estritamente crescente em $[t_2, \infty)$.*

Suponha que um minimizador de φ pertence ao intervalo $[a, b]$.

1. Considere $a < u < v < b$ em $[0, \infty)$;
2. Se $\varphi(u) < \varphi(v)$ então o trecho $[v, b]$ não pode conter um minimizador e pode ser descartado;
3. Se $\varphi(u) \geq \varphi(v)$ então o trecho $[a, u]$ pode ser descartado;
4. Particione o intervalo que ficou e repita o processo.

Sera abordado como particionar o intervalo $[a, b]$. A obtenção deste intervalo, que deve conter um minimizador de φ, será tratada adiante.Uma estratégia que parece natural é dividir p o-intervalo em três partes iguais, ou seja definir

$$u = a + \frac{1}{3}(b - a) \text{ e } v = a + \frac{2}{3}(b - a).$$

Assim, descarta-se $\frac{1}{3}$ do intervalo corrente a cada etapa. Entretanto, esta forma de particionar o intervalo tem um desvantagem. Precisamos fazer duas novas avaliações de função por etapa, pois o ponto que sobrou, u ou v não pode ser aproveitado. A estratégia que veremos a seguir, consiste em escolher os pontos u e v que dividem o segmento $[a, b]$ na razão áurea, de acordo com a seguinte definição.

Definição 25. *Um ponto c divide o segmento segmento [a,b] na razão áurea quando a razão entre o maior segmento e o segmento todo é igual à razão entre o menor e o maior segmentos. Tal razão é conhecida como o número de ouro e vale $\frac{\sqrt{5}-1}{2} \approx 0,618$*

Ou seja, u e v devem satisfazer:

$$\frac{b-u}{b-a} = \frac{u-a}{b-u} \text{ e } \frac{v-a}{b-a} = \frac{b-v}{v-a} \tag{3.2}$$

Considerando θ_1 e θ_2 tais que

$$u = a\theta_1(b-a) \text{ e } v = a + \theta_2(b-a), \tag{3.3}$$

obtemos 1-$\theta_1 = \frac{\theta_1}{1-\theta_1}$ e $\theta_2 = \frac{1-\theta_2}{\theta_2}$. Portanto,

$$\theta_1 = \frac{3-\sqrt{5}}{2} \approx 0,382 \text{ e } \theta_2 = \frac{\sqrt{5}-1}{2} \approx 0,618.$$

Note que

$$\theta_1 + \theta_2 = 1 \text{ e } \theta_2^2 = \theta_1 \tag{3.4}$$

Uma das vantagens da divisão na razão áurea em relação à divisão em três partes iguais é que descartamos mais de 38%do intervalo ao invés de $33,33\%$. Outra vantagem se refere a economia em avaliação de função como veremos a seguir.

No processo iterativo, a cada etapa descartamos o intervalo $[a,u]$ ou $[v,b]$, obtendo um novo segmento que deverá ser particionado novamente. Indicamos por $[a^+,b^+]$ o novo intervalo que será particionado pelos ponto u^+ e v^+.

Lema 7. *No método da seção áurea, se $[v,b]$ é descartado então $v^+ = u$. Analogamente, se $[a,u]$ é descartado então $u^+ = v$.*

Demonstração. (i) Como $[a,u)$ foi descartado, então $u = a$ e $b = b^+$. Daí, temos usando o (3.3) que

$$v^+ = a^+ + \theta_2(b^+ - a^+) = a + \theta_2(v-a)$$

Utilizando (3.3) novamente a relação (3.4), obtemos

$$v^+ = a + \theta_2^2(b-a) = a + \theta_1(b-a) = u,$$

Provamos assim a primeira afirmação. a outra afirmação se prova de forma análoga ■

Iremos apresentar, o algoritmo da seção áurea, que tem duas fases. Na primeira, obtemos um intervalo $[a,b]$ que contém um minimizador de φ. Vamos considerar um intervalo inicial $[0,2\rho]$, com $\rho > 0$, ampliá-lo, deslocando para

a direita, até que um crescimento de φ seja detectado. Depois, o intervalo $[a, b]$ é reduzido, por meio do descarte de subintervalos, até que reste um intervalo de tamanho suficiente para que uma precisão ε seja assegurada

Figura 3 – Algoritmo 2 Seção Áurea

Dados: $\varepsilon > 0$, $\rho > 0$, $\theta_1 = \dfrac{3-\sqrt{5}}{2}$, $\theta_2 = 1 - \theta_1$
Fase 1: Obtenção do intervalo $[a, b]$
$a = 0$, $s = \rho$ e $b = 2\rho$
REPITA enquanto $\varphi(b) < \varphi(s)$
    $a = s$, $s = b$ e $b = 2b$
Fase 2: Obtenção de $\bar{t} \in [a, b]$
$u = a + \theta_1(b - a)$, $v = a + \theta_2(b - a)$
REPITA enquanto $(b - a) > \varepsilon$
    SE $\varphi(u) < \varphi(v)$
        $b = v$, $v = u$, $u = a + \theta_1(b - a)$
    SENÃO
        $a = u$, $u = v$, $v = a + \theta_2(b - a)$
Defina $\bar{t} = \dfrac{u+v}{2}$

3.2.2 Busca Inexata- Condição de Armijo

Em algumas situações, φ não é unimodal, neste caso, aplicar a busca exata não é algo adequado. A condição de Armijo será a apresentada, procura uma boa redução da função ao longo da direção, sem tentar minimizá-la.

Dado um ponto $\bar{x} \in \mathbb{R}^n$, uma direção de descida $d \in \mathbb{R}^n$ e $n \in (0, 1)$. A regra de Armijo encontra $\bar{t} > 0$ tal que

$$f(\bar{x} + \bar{t}d) \leq f(\bar{x}) + \eta \bar{t} f(\bar{x})^T d \tag{3.5}$$

Esta desigualdade é conhecida como condição de Armijo, e exige que o decréscimo em f seja proporcional ao tamanho do passo $\bar{t}$.

Teorema 19. *Considere um função diferenciável* $f : \mathbb{R}^n \to \mathbb{R}$*, um ponto* $\bar{x} \in \mathbb{R}$*, uma direção de descida* $d \in \mathbb{R}^n$ *e* $\eta \in (0, 1)$*. Então existe* $\delta > 0$ *tal que*

$$f(\bar{x} + td) \leq f(\bar{x}) + nt\nabla f(\bar{x})^T d$$

para todo $t \in [0, \delta)$

Demonstração. Caso $\nabla f(\bar{x})^T d = 0$,o resultado segue da definição de direção de descida. Suponha então que $\nabla f(\bar{x})^T d < 0$. Deste modo, como $\eta < 1$, temos

$$\lim_{t \to 0} \frac{f(\bar{x} + td) - f(\bar{x})}{t} = \nabla f(\bar{x} + td) - f(\bar{x}) < \eta \nabla f(\bar{x})^T d$$

portanto, existe $\delta > 0$ tal que

$$\frac{f(\bar{x} + td) - f(\bar{x})}{t} < \eta \nabla f(\bar{x})^T d \tag{3.6}$$

para todo $t \in (0, \delta)$. O que nos leva a

$$f(\bar{x} + td) \leq f(\bar{x}) + \eta t \nabla f(\bar{x})^T d$$

Como queríamos demonstrar. ■

Algoritmo 3 - Busca de Armijo
Dados: $\bar{x} \in \mathbb{R}^n, d \in \mathbb{R}$(direção de descida), $\gamma, \eta \in (0, 1)$
$t = 1$
REPITA enquanto $f(\bar{x} + td) > f(\bar{x}) + \eta t \nabla f(\bar{x})^T d$
$t = \gamma t$

3.3 Método das Direções Conjugados

Métodos de direções conjugadas são métodos de primeira ordem (usam apenas informações da função e do gradiente) com convergência mais rápida que o método de Cauchy e custo computacional menor do que Newton. Enquanto Cauchy pode gastar uma infinidade de passos para resolver uma quadrática, Newton a resolve em um passo. Veremos que os métodos de direções conjugadas minimizam uma quadráticas definida em $\mathbb{R}^n$ usando no máximo n passos.

3.3.1 Direções Conjugadas

Para apresentar o assunto será abordados definições e resultados.

Definição 26. *Seja $A \in \mathbb{R}^{n\times n}$ uma matriz definida positiva. Dizemos que os vetores $d^0, d^1, \ldots, d^k \in \mathbb{R}^n \setminus \{0\}$ são A-conjugados se*

$$(d^i)^T A d^j = 0$$

para todos $i, j = 0, 1, \ldots, k$ com $i \neq j$.

Lema 8. *Seja $A \in \mathbb{R}^{n\times n}$ uma matriz definida positiva. Um conjunto qualquer de vetores A-conjugados é linearmente independente.*

Demonstração. Sejam $d^0, d^1, \ldots, d^k \in \mathbb{R} \setminus 0$ vetores A-conjugados. Consideramos as constantes $a_0 + a_1 + \cdots + a_k \in \mathbb{R}$ tais que

$$a_0 d^0 + a_1 d^1 + \cdots + a_k d^k = 0$$

■

Dado $i \in \{0, 1, \ldots, k\}$, multiplicando os dois membros da igualdade acima por

$$(d^i)^T A d^i = 0$$

, donde segue que $a_i = 0$, pois A é definida positiva.

Veremos agora que o conhecimento de direções conjugadas permite obter o minimizador de uma função quadrática. Considera a função $f : \mathbb{R}^n \to \mathbb{R}$ dada por

$$f(x) = \frac{1}{2} x^T A x + b^T x + c \tag{3.7}$$

com $A \in \mathbb{R}^{n\times n}$ definida positiva, $b \in \mathbb{R}^n$ e $c \in \mathbb{R}$. A função f tem um único minimizador x^*, que é global e satisfaz

$$Ax^* + b = \nabla f(x^*) = 0 \tag{3.8}$$

.

Dado um conjunto qualquer de direções A-conjugadas $\{d^0, d^1, \ldots, d^{n-1}\}$, vamos definir uma sequência finita do seguinte modo: tome $x^0 \in \mathbb{R}^n$ arbitrário e defina para $k = 0, 1, \ldots, n-1$

$$x^{k+1} = x^k + t_k d^k, \tag{3.9}$$

onde

$$t_k = \arg_{t\in\mathbb{R}} \min\{f(x^k + td^k)\}$$

Note que a minimização acima é calculada sobre toda a reta. Podemos perceber que d^k pode não ser direção descida para f no ponto x^k. Além disso, como f é quadrática, podemos obter uma fórmula explícita para t_k. Para isso, defina $\varphi : \mathbb{R} \to \mathbb{R}$ por $\varphi(t) = f(x^* + td^k)$.

Usando a definição de t_k, obtemos

$$\nabla f(x^{k+1})d^k = \nabla f(x^k + t^k d^k) = \varphi'(t_k) = 0. \tag{3.10}$$

Por outro lado, temos

$$\nabla f(x^{k+1}) = Ax^k + t_k d^k + b = \nabla f(x^k) + t^k A d^k$$

Substituindo isto em (3.10), obtemos

$$t_k = -\frac{\nabla f(x^k)^T d^k}{(d^k)^T A d^k} \tag{3.11}$$

O teorema a seguir mostra, que o algoritmo dado por (3.9) minimiza a quadrática definida anteriormente na equação (3.9) e seu minimizador x^*, definido em (3.8).

Teorema 20. *Consideremos a função quadrática dado por (3.7) e seu minimizador x^*. Dado $x^0 \in \mathbb{R}^n$, a sequência finita, temos que $x^n = x^*$.*

Demonstração. Pelo Lema 8, temos que o conjunto $\{d^0, d^1, \ldots, d^k\}$ é uma base de $\mathbb{R}^n$. Portanto, existem escalares $\alpha_i \in \mathbb{R}^n, i = 0, 1, \ldots, n-1$,tais que

$$x^* - x^0 = \sum_{i=0}^{n-1} \alpha_i d_i. \tag{3.12}$$

Consideremos um k arbitrário. Multiplicando a relação acima por $(d^k)^T$ e levando em conta que as direções conjugadas, temos que

$$(d^k)^T A(x^* - x) = \alpha_k (d^k)^T A d^k$$

Assim,

$$\alpha_k = \frac{(d^k)^T A(x^k - x^0)}{(d^k)^T A d^k}$$

Por outro lado, pela definição de x^k em (3.9), temos

$$x^k = x^0 + t_0 d^0 + t_1 d^1 + t_2 d2 + \cdots + t_{k-1} d^{k-1}$$

que multiplicando por $(d^k)^T A$, implica

$$((d^k)^T A x^k) = (d^k)^T A x^0,$$

pois as direções são A-conjugados. Substituindo isto em α_k e usando em (3.8), obtemos

$$\alpha_k = -\frac{(d^k)^T (b + Ax^k)}{(d^k)^T A d^k} = -\frac{(d^k)^T \nabla f(x)}{(d^k)^T A d^k} = t_k$$

Temos pela equação (3.12) segue que

$$x^* = x^0 + \sum_{i=0}^{n-1} t_i d^i = x^n,$$

assim como queríamos demonstrar. ■

Lema 9. *Dado $x^0 \in \mathbb{R}^n$, considere a sequência finita definida em (3.9). Então*

$$\nabla f(x^k)^T d^j = 0$$

para todo $j = 0, 1, \ldots, k-1$.

Demonstração. Utilizaremos a relação (3.10),temos que

$$\nabla f(x^k)^T d^{k-1} = 0,$$

para $j < k - 1$

$$(\nabla f(x^{k-1}) t_{k-1} A d^{k-1})^T d^j = (\nabla f(x^{k-1}) - \frac{\nabla f(x^{k-1})^T d^{k-1}}{(d^{k-1})^T A d^{k-1}} A d^{k-1})^T d^j$$

$$= (\nabla f(x^{k-1}) - \nabla f(x^{k-1}))^T d^j = \nabla f(x^{k-1})^T d^j = 0$$

Provaremos para $k + 1$

$$(\nabla f(x^{k+1}))^T d^j$$

para $j = k - 1$

$$(\nabla f(x^{k+1}) + t_j A d^k)^T d^j = (\nabla f(x^k) t_j A d^k)^T d^j =$$

$$= (\nabla f(x^j) - \frac{\nabla f(x^k)^T d^k}{(d^k)^T A d^k} A d^k)^T d^j$$

$$(\nabla f(x^k))^T d^j = 0$$

Como queríamos demonstrar. ■

3.3.2 Algoritmo das direções conjugados para funções quadráticas

Na seção anterior observamos como obter o minimizador de uma função quadrática estritamente convexa a partir de um conjunto de direções conjugadas. Desenvolveremos agora um método para gerar as direções.

Dados $x^0 \in \mathbb{R}^n$, defina $d^0 = -\nabla f(x^0)$e, para $k = 0, 1, \ldots, n - 2ne$

$$d^{k+1} = -\nabla f(x^{k+1}) + \beta_k d^k,$$

onde x^k é dado por pela equação 3.9 e β_k sendo que calculamos de tal forma que d^k e d^k sejam A-conjugados, ou seja,

$$(d^k)^T A(-\nabla f(x^{k+1}) + \beta_k d^k) = (d^k)^T A d^{k+1} = 0$$

Isto nos fornece

$$\beta_k = \frac{(d^k)^T A \nabla f(x^{k+1})}{(d^k)^T A d^k} \tag{3.13}$$

Construiremos a seguir o algoritmo da direções conjugados.

O algoritmo

Figura 4 – Algoritmo 3 Direções Conjugadas

Dado $x^0 \in \mathbb{R}^n$, faça $d^0 = -\nabla f(x^0)$
$k = 0$
REPITA enquanto $\nabla f(x^k) \neq 0$
$t_k = -\frac{\nabla f(x^k)^T d^k}{(d^k)^T A d^k}$
$x^{k+1} = x^k + t_k d^k$
$\beta_k = \frac{(d^k)^T A \nabla f(x^{k+1})}{(d^k)^T A d^k}$
$d^{k+1} = -\nabla f(x^{k+1}) + \beta_k d^k$
$k = k + 1$

O algoritmo 3 está bem definido, isto é, se $\nabla f(x^k) \neq 0$, então $d^k \neq 0$, como pode ser visto pela relação que veremos a seguir. Assim, o novo ponto pode ser calculado. Outra característica deste algoritmo, que não era necessariamente válida para direções conjugadas em geral, é que as direções geradas aqui são descida. E usando a relação da equação (3.10) mostrada anteriormente

$$\nabla f(x^k)d^k = \nabla f(x^k)^T(-\nabla f(x^k) + \beta_{k-1}d^{k-1}) = - \parallel \nabla f(x^k) \parallel^2 . \quad (3.14)$$

Teorema 21. *Se x^k e d^k foram geradas pelo algoritmo das direções conjugadas temos que*

$$\nabla f(x^k)^T \nabla f(x^j) = 0 \ e \ (d^k)Ad^j = 0,$$

para todo $j = 0, 1, \ldots, k-1$.

Demonstração. Vamos utilizar a notação $g_i = \nabla f(x^i)$, para simplificar os cálculos. Sabemos que a definição de β_0 e pela equação (3.13) implica que $(d^1)^A d^0 = 0$. Provaremos por indução matemática. Então temos

$$(g_1)^T g_0 = 0$$

e usando o Lema 9, sabemos que

$$(\nabla f(x^k))^T d^j = 0$$

Então primeiramente demonstraremos para k e $j < k-1$

$$g_k^T g_j = g_k^T(-d^j + \beta_{j-1}d^{j-1}) = g_k^T(-d^j + \frac{(d^{j-1})^T A \nabla f(x^j)}{(d^{j-1})^T A d^{j-1}} d^{j-1})$$

$$-g_k^T(d^j) = k$$

vamos provar para $j = k-1$ e para $k+1$

$$g_{k+1}^T g_j = g_{k+1}^T(-d^j + \beta_{j-1}d^{j-1})$$

$$g_{k+1}^T(-d^j + \frac{(d^{j-1})^T A \nabla f(x^j)}{(d^{j-1})^T A d^{j-1}} d^{j-1})$$

$$(\nabla f(x^k) + t_j A d^k)^T(-d^j + \frac{(d^{j-1})^T A \nabla f(x^j)}{(d^{j-1})^T A d^{j-1}} d^{j-1})$$

$$(\nabla f(x^k))^T d^j = 0$$

provaremos a segunda parte para $(d^k)Ad^j = 0$, sabemos que $\nabla f(x^{k+1}) = \nabla f(x^k) + t^k A d^k$ então vamos provar por indução vamos começar provando para $j < k-1$ e para k.

$$(d^k)Ad^j = (-g_k + \beta_{k-1}d^{k-1})A(-g_{k-1} + \beta_j d^j)$$

$$= -g_k A d^j$$

Sabemos que $Ad^j = \frac{g_{k+1}-g_k}{t_k}$

$$= g_k(\frac{g_{j+1} - g_j}{t_j}) = 0$$

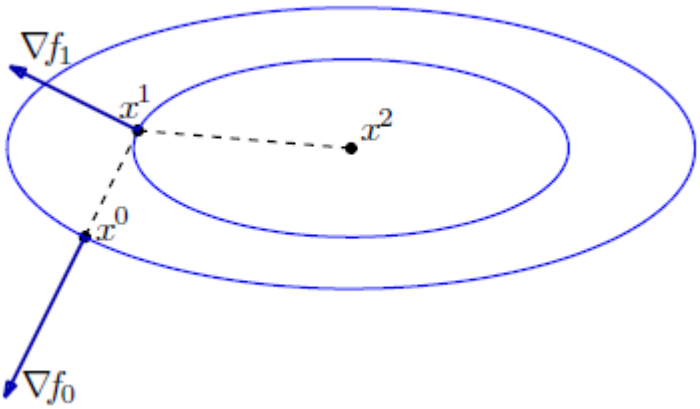
Para $k+1$ fica a equação nesta maneira

$$g_{k+1}Ad^j = g_{k+1}(\frac{g_{j+1} - g_j}{t_j}) = 0$$

■

A figura abaixo ilustra aplicação do algoritmo de gradientes conjugados para a otimização de função quadráticas em $\mathbb{R}^2$. Percebemos que a ortogonalidade dos gradientes, assim percebemos uma iteração obtendo resultado em duas iterações.

Figura 5 – (RIBEIRO; KARAS, 2001)



β_k tem que seu calculo computacional muito caro por fazer operações com produtos com a matriz Hessiana. Apresentamos a seguir outras formas de

calcular este coeficiente. Umas delas, proposta por Polak e Ribière (POLAK; RIBIERE, 1969), é dada por

$$\beta_k^{PR} = \frac{\nabla f(x^{k+1})^T \nabla f(x^{k+1}) - \nabla f(x^k)}{\nabla f(x^k)^T \nabla f(x^k)} \tag{3.15}$$

enquanto a outra, devida a Fletcher e Reever (FLETCHER; REEVES, 1964) mostra que considera

$$\beta_k^{FR} = \frac{\nabla f(x^{k+1})^T \nabla f(x^{k+1})}{\nabla f(x^k)^T \nabla f(x^k)} \tag{3.16}$$

As expressões acima tem vantagem computacional de utilizar apenas produtos de vetores e coincidem no caso quadráticos, porém para funções não quadráticas as funções não coincidem no mesmo valor, o que diversifica nossas alternativas para melhoras nosso método.

Teorema 22. *Se f é uma função quadrática, então as expressões (3.13),(3.15) e (3.16) elas coincidem*

$$\beta_k = \beta_k^{PR} = \beta_k^{FR} \tag{3.17}$$

Demonstração. Usaremos novamente a notação $g_i = \nabla f(x_i)$. Por (3.10), temos que

$$Ad^k = \frac{g_{k+1} - g_k}{t_k}$$

Portanto

$$\beta = \frac{g_{k+1}^T A d^k}{(d^K)^T A d^K} = \frac{g_{k+1}^T (g_{k+1} - g_k)}{(d^k)^T (g_{k+1} - g_k)}$$

■

3.3.3 Extensão para funções não-quadráticas

A extensão do método vai ser adaptado para minimização de funções não quadráticas. Para tanto é necessário planejar a melhor forma como calcular o tamanho do passo t_k e o coeficiente β_k. A busca linear, no caso quadrático era feita de forma fechada pela fórmula da equação (3.11) iremos utilizar métodos unidimensionais discutidos anteriormente. Para cálculo de β_k, podemos utilizar as maneiras (3.15) e (3.16). Assim iremos abranger as formas

de iteração do método dando mais diversidade para encontrar as soluções. E temos que estas variantes para funções não quadráticas não terminam necessariamente em n passos. Então iremos reinicializar a busca a cada n passos, fazendo $\beta_k = 0$, o equivale a tomar direção do gradiente. Assim construímos o seguinte algoritmos.

Observação 2. *Essa variação para funções não necessariamente termina em n passos. Sendo assim iremos reinicializar as direções de busca fazendo* $\beta_k = 0$, *o equivalente a tomar a direção do gradiente. Notamos que se* t_k *for calculado por uma minimização unidirecional local, então as direções conjugadas geradas pelo Algoritmo das direções conjugadas são de descidas. Porém, a busca de Armijo não assegura tal propriedade.*

Figura 6 – O algoritmo para funções não quadráticas

Dado $x^0 \in \mathbb{R}^n$, faça $d^0 = -\nabla f(x^0)$
$k = 0$
REPITA enquanto $\nabla f(x^k) \neq 0$
    Calcule o comprimento do passo t_k
    Faça $x^{k+1} = x^k + t_k d^k$
    SE $(k+1) \bmod n \neq 0$

β será escolhido por β_k^{FR} ou β_k^{PR}

Figura 7 – O algoritmo para funções não quadráticas

Defina $d^{k+1} = -\nabla f(x^{k+1}) + \beta_k d^k$
$k = k + 1$

3.4 Teste Computacional

3.4.1 Funções quadráticas

Nos teste computacionais, foram calculados alguns exemplos para funções quadráticas era feita de forma

$$f(x) = \frac{1}{2}x^T Ax + bx + c$$

com o $\nabla f(x)$:

$$\nabla f(x) = x^T A + b$$

Só precisamos das informações do gradiente, foram realizados dois testes. O primeiro teste

$$x = [1, 1, 1, 1]$$

$$A = \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix}$$

$$b = [1, 1, 1, 1]$$

O método convergiu com 376 Iterações

Iteração	**x**	**A**	**b**	**ponto de mínimo** $(x^*)^T$
376	[1,1,1,1]	$A = \begin{bmatrix} 9 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix}$	[1,1,1,1]	$\begin{bmatrix} -8.87931427e-18 \\ -2.00000000e+00 \\ -1.33467996e-16 \\ 1.00000000e+00 \end{bmatrix}$
3	10	42,5	-12	0.2823529411764706

O método de Newton obteve o mesmo resultado de iterações para a segunda função estudada. E a primeira função a matriz A é singular logo o método de Newton não pode iterar e nem convergir.

3.4.2 Funções não-quadráticas

3.4.2.0.1 Funções Exatas

Método	função	x	ponto de minimo	Iteração k	Beta
Newton	$x^4 - 4x^3 + 6x - 4 + 1$	0	0,991	2	Não tem
GC	$x^4 - 4x^3 + 6x - 4 + 1$	0	1,0007	1	PR
GC	$x^4 - 4x^3 + 6x - 4 + 1$	0	1	1	FR
Newton	$-x^3 + 4x^2 + +3x + 4$	0	-0.33333238708343566	19	Não tem
GC	$-x^3 + 4x^2 + +3x + 4$	0	-0.3333333747657136	1	PL
GC	$-x^3 + 4x^2 + +3x + 4$	0	-0.3333333747657136	1	FR

O método dos direções conjugadas para funções exatas se mostrou bastante eficiente, para essas funções estudadas encontrando o resultado em uma iteração. Em comparação a newton o método foi rápido em encontrar o ponto de mínimo. Nota-se que para funções essas funções os Beta diferentes tiveram o mesmo desempenho.

3.4.2.0.2 Funções inexatas

Método	função	x	ponto de minimo	Iteração k	Beta
Newton	$-x^3 + 6x^2 + 20x + 3$	0	-1.2660	9	Não tem
GC	$-x^3 + 6x^2 + 20x + 3$	0	0,99993	2472	PR
GC	$-x^3 + 6x^2 + 20x + 3$	0	0.9993	64726	FR
Newton	$-x^3 + y^3 - 3x - 3y + 4$	0	1,1	11	Não tem
GC	$-x^3 + y^3 - 3x - 3y + 4$	0	Não convergiu	100000	PR
GC	$-x^3 + y^3 - 3x - 3y + 4$	0	1,1	64726	FR

O método para funções inexatas é um método eficaz, mas a outros métodos eficientes, pois o método Direções Conjugados faz iterações em pequenos passos para as funções. A matriz selecionada foi A = 1 , a matriz mais simples, e percebendo o número de iterações nestas funções, compreende-se que optar por métodos diferentes é uma opção a se considerar. A comparação com o método de Newton denotou que a diferença de iterações é gigantesca. E algumas vezes as funções pelo método das direções conjugado não convergiam pelo Beta de Polak e Rubiere.

Considerações Finais

O projeto tem sua primeira parte bem rica em conceitos de fácil compreensão sobre Introdução a Otimização e Convexidade. E abordando ótimos algoritmos e métodos para funções exatas e inexatas. O método dos gradientes conjugados é um método bastante interessante, pois usa matrizes definidas positivas e o gradiente sendo uma boa opção para uma função com muitos vetores.

Com auxílio de programas de computador foi utilizado a linguajem Python para construção do algoritmos sendo assim analisamos a real eficiência do método. Sendo que direções conjugados é feito com propósito de calcular funções quadráticas tendo ótimos resultados nesta iterações. A extensão para funções não-quadráticas, mostra-se de grande utilidade para funções exatas, porém para inexatas eles se torna lento, fazendo muitas iterações. Sendo um método de grande utilidade para minimizar funções irrestritas.

Agradecimentos

Em primeiro lugar quero agradecer a Deus por ter me concedido um excelente orientador Prof. Dr. Roberto Cristóvão Mesquita Silva e quero agradecer a ele por sua paciência em me orientar em toda sua disponibilidade de tempo e as horas em que me ajudou nas demonstrações e duvidas.

Quero agradecer também ao Professor Mestre Roberto Prata por sempre está me ajudando e aconselhando neste curso e todas as vezes em que lhe pedi ajuda ele se disponibilizou em todas essas vezes sempre procurando o melhor dos alunos.

E muito obrigado a minha mãe e minha namorada por me apoiarem neste trabalho. E agradecer a amigos e família pelas palavras encorajadoras por terem me ajudado a concluir este trabalho.

Referências

ESTEVAM, L. N. Uma abordagem do método de newton para minimização irrestrita. 2020.

FLETCHER, R.; REEVES, C. M. minimizaçao de funçao por gradientes conjugados. v. 7, n. 2, p. 149–154, 1964.

LIMA, E. L. *Análise real*. [S.l.]: Impa Rio de Janeiro, 2004. v. 2.

MOTA, A. *Convergência de algoritmos para programaçao nao linear*. Tese (Doutorado) — Master's thesis, Universidade Federal do Paraná, Curitiba, PR, 2005.

POLAK, E.; RIBIERE, G. Note sur la convergence de méthodes de directions conjuguées. *ESAIM: Mathematical Modelling and Numerical Analysis-Modélisation Mathématique et Analyse Numérique*, v. 3, n. R1, p. 35–43, 1969.

RIBEIRO, A. A.; KARAS, E. W. Um curso de otimizaçao. *Universidade de Curitiba, Curitiba, Brasil*, 2001.

Cronograma

Nº	**Descrição**	Ago	Set	Out	Nov	Dez	Jan	Fev	Mar	Abr	Mai	Jun	Jul
1	Sequência	x	x										
2	Introdução a Otimização			x									
3	Convexidade				x								
4	Algoritmos					x				x	x	x	
5	Preparação do relatório final						x	x	x	x	x	x	
6	Preparação da Apresentação Final											x	x